

---

# INFERENCIA ESTADÍSTICA II

---

## Tema 4: Técnicas de Bondad de Ajuste

### **Author**

Victor Elvira Fernández, Tomás Ruiz Rojo, Juan Horrillo Crespo  
Universidad de Valladolid

22 de diciembre de 2024

# AVISO

Estos apuntes fueron creados de forma voluntaria por un grupo de estudiantes, invirtiendo tiempo, dedicación y esfuerzo para ofrecer información útil a la comunidad. Apreciamos cualquier apoyo que se nos quiera brindar, ya que nos ayuda a continuar con futuros proyectos de este tipo.

Si deseas colaborar en esta clase de proyectos puedes contactarnos y unirte o invitarnos a unas ricas patatas 5 salsas por el siguiente enlace:

## Buy Me a Patatas 5 Salsas

<https://www.buymeacoffee.com/ApuntesINdat>

- Mail Juan Horrillo
- Mail Victor Elvira
- Mail Tomás Rojo

Si has colaborado de cualquier forma te agradecemos enormemente.

# Índice

<b>1. Introducción al test de Bondad de Ajuste</b>	<b>4</b>
1.1. Test Chi-Cuadrado de Bondad de Ajuste . . . . .	5
1.2. Distribución del test bajo $H_1$ . . . . .	8
<b>2. Test de Kolmogorov-Smirnov</b>	<b>10</b>
2.1. Test de Kolmogorov-Smirnov para hipótesis simples . . . . .	10
2.2. Test de Kolmogorov-Smirnov para una hipótesis compuesta . . . . .	12
<b>3. Test de Shapiro-Wilk</b>	<b>13</b>
<b>4. Primer examen parcial</b>	<b>14</b>

# 1. Introducción al test de Bondad de Ajuste

Hasta ahora los problemas planteados parten de unos datos obtenidos en un experimento aleatorio del que se conoce el mecanismo con el que se genera (Familia de distribución  $P_\theta$ ).

**Definición:** El Test de Bondad de Ajuste es un test para comprobar si una familia de distribuciones, representa correctamente el mecanismo con el que se generaron los datos.

Planteamiento:

$X_1, \dots, X_n$  con función de distribución  $F$ . Si  $F_0$  es una función de distribución conocida, (por ejemplo, una Poisson con  $\lambda = 3$ ), el problema se reduce a:

$$H_0 : F = F_0 \quad H_1 : F \neq F_0$$

$F_0$  está completamente especificada, por lo que es una hipótesis simple.

La hipótesis nula sería compuesta si  $F_0$  depende de parámetros desconocidos, por ejemplo, una  $P(\lambda)$

Empezaremos con el caso de  $H_0$  simple. Existen dos tipos de Test de Bondad de Ajuste si  $F_0$  es una función de distribución conocida.

1.  $F_0$  discreta: Se comparan las frecuencias observadas con las esperadas bajo  $H_0$  (Test  $\chi^2$ ). También se puede hacer si  $F_0$  es continua agrupando, pero hay tests más potentes para esos casos.
2.  $F_0$  continua: Comparamos la función de distribución empírica con la teórica.




Figura 1: Visualización de una distribución teórica y empírica

## 1.1. Test Chi-Cuadrado de Bondad de Ajuste

Sea  $X_1, \dots, X_n$  con distribución F discreta:

$$\begin{array}{l} C_1 \rightarrow P_1 \\ \dots \\ C_k \rightarrow P_k \end{array} \quad p_j \geq 0, \quad \sum_{j=1}^n p_j = 1$$

Caso en el que  $F_0$  completamente especificada bajo  $H_0$ :

$$H_0 : p = p^0 \quad p = (p_1, \dots, p_k)'$$

$$H_1 : p \neq p^0 \quad p^0 = (p_1^0, \dots, p_k^0)'$$

Este problema ya lo sabemos resolver: es un contraste para el parámetro  $p$  de una distribución multinomial.

Frecuencia observada en  $C_j : f_j = \sum_{i=1}^n \mathbb{1}_{(x_i=c_j)}, \quad j = 1, \dots, k \quad \sum_{j=1}^k f_j = n$

Frecuencia esperada bajo  $H_0$  en  $C_j$ :

$$e_j = n \cdot P_0(x = c_j) = n \cdot p_j^0$$

### Ejemplo:

Sea una variable aleatoria  $X$  cuya función de masa de probabilidad es la siguiente

$$P(X = x) = \begin{cases} \frac{1}{3} & \text{si } x = 0 \\ \frac{1}{3} & \text{si } x = 1 \\ \frac{1}{3} & \text{si } x = 2 \end{cases}$$

Entonces la hipótesis nula para el test será que

$$H_0 : \quad p_1 = \frac{1}{3} \quad p_2 = \frac{1}{3} \quad p_3 = \frac{1}{3}$$

Tomando una muestra de  $n=10$  quedan 7 ceros, 2 unos y 1 dos.

A simple vista no parece que siga esa distribución. Usaremos un estadístico para medir que tan diferente es de nuestra distribución pues lo que esperabamos obtener es:

$$e_1 = 3,33$$

$$e_2 = 3,33$$

$$e_3 = 3,33$$

El test  $\chi^2$  de ajuste proporciona unas bases probabilísticas para decidir si las diferencias son suficientemente grandes tal que no hayan ocurrido por puro azar. Se define como

$$\chi^2 = \sum_{j=1}^k \frac{(f_j - e_j)^2}{e_j}$$

Este estadístico es lo que se conoce como distancia  $\chi^2$  entre  $f_j$  y  $e_j$ . Para valores grandes

en  $\chi^2$  implica frecuencias observadas y esperadas muy diferentes.

Fijado  $\alpha$ :

- Región crítica:  $(\chi^2 > C_\alpha)$
- p-valor:  $p_0(\chi^2 > X_{obs}) = p_0(\chi^2 > t_{obs})$

Necesitamos conocer la distribución del estadístico bajo  $H_0$ . Se podría conocer de forma exacta aunque es muy complejo, por ello, nos interesará la distribución asintótica para  $n$  grande.

**Resultado:**

$$\lim_{n \rightarrow \infty} P_0(\chi^2 \leq Z) = P(\chi_{k-1}^2 \leq Z)$$

La distribución asintótica del estadístico  $\chi^2$  bajo  $H_0$  es  $\chi_{k-1}^2$ .

Ya hemos visto que en este contexto  $F_0$  es una distribución multinomial. Vamos a ver que el estadístico  $T$  bajo  $H_0$  para el modelo multinomial con  $k - 1$  parámetros libres es asintóticamente equivalente al estadístico  $\chi_1^2$ .

**Demostración 1.1.** Estadístico RV para:

$$H_0 : F = F_0$$

$$H_1 : F \neq F_0$$

Recordemos:

$$L(p, x) = \prod_{j=1}^k p_j^{f_j} \implies \log L(p, x) = \sum_{j=1}^k f_j \log p_j$$

El estadístico es:

$$\begin{aligned} T &= 2 [\log L(\hat{p}, x) - \log L(p_0, x)] = 2 \left[ \sum_{j=1}^k f_j \log \hat{p}_j - \sum_{j=1}^k f_j \log p_j^0 \right] \\ &= -2 \sum_{j=1}^k (\log p_j^0 - \log \hat{p}_j) \end{aligned}$$

Aproximamos  $\log p_j^0$  por un desarrollo de Taylor en torno a  $\log \hat{p}_j$ :

$$\begin{aligned} \log p_j^0 &\approx \log \hat{p}_j + (p_j^0 - \hat{p}_j) \frac{1}{\hat{p}_j} - \frac{(p_j^0 - \hat{p}_j)^2}{2 \cdot \hat{p}_j^2} + \dots \\ \rightarrow \log p_j^0 - \log \hat{p}_j &\approx (p_j^0 - \hat{p}_j) \frac{1}{\hat{p}_j} - \frac{(p_j^0 - \hat{p}_j)^2}{2} \frac{1}{\hat{p}_j^2} \end{aligned}$$

... Sabiendo que  $\hat{p}_j = \frac{f_j}{n}$

$$= \left( p_j^0 - \frac{f_j}{n} \right) \cdot \frac{n}{f_j} - \frac{\left( p_j^0 - \frac{f_j}{n} \right)^2}{2} \cdot \left( \frac{n}{f_j} \right)^2 \xrightarrow{c.s.} 0$$

Esto converge a 0, ya que, por la Ley de los Grandes Números (LGN),  $\frac{F_j}{n}$  es un estimador consistente de  $p_j$ :

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{F_j}{n} - p_j \right| > \varepsilon \right) = 0 \quad \forall \varepsilon > 0$$

Por lo tanto, el estadístico T queda:

$$T = -2 \sum_{j=1}^k (n \cdot p_j^0 - f_j) + \frac{\sum_{j=1}^k (f_j - n \cdot p_j^0)^2}{f_j}$$

El test  $\chi^2$  y el TRV son asintóticamente equivalentes y como TRV converge a  $\chi_{k-1}^2$ , el estadístico  $\chi^2$  también. Fijado un  $\alpha$ .

- Región crítica:  $P_0(\chi^2 \geq C_\alpha) \quad C_\alpha = qchisq(1 - \alpha, k - 1)$
- p-valor:  $P_0(\chi^2 \geq t_{obs}) = 1 - qchisq(t_{obs}, k - 1)$

*Nota:*

Esta aproximación es válida para frecuencias mayores o iguales a 5

### Ejercicio 1: Script R

**Ejercicio 4:** En una fábrica con 220 empleados, el número de trabajadores que tuvieron accidentes se recoge en la tabla siguiente:

Nº accidentes	0	1	2	3	4	5	6+
Nº trabajadores	181	9	4	10	7	4	5

¿Son estos datos consistentes con la distribución de Poisson con  $\lambda = 1$ ?

Tenemos una hipótesis compuesta ya que no conocemos el parámetro de la Poisson. Si nos dijeran  $P(1)$  sería simple.

$$f(x, 1) = \frac{e^{-1} \cdot \lambda^x}{x!} = \frac{e^{-1}}{x!}$$

$$p_0^0 = e^{-1}, \quad p_1^0 = e^{-1}, \quad p_2^0 = \frac{e^{-1}}{2}, \quad \dots, \quad p_6^0 = 1 - \sum_{j=0}^5 p_j^0$$

Calculamos las frecuencias esperadas

$$e_0 = 220 \cdot e^{-1}, \quad e_1 = 220 \cdot e^{-1}, \quad \dots$$

$$\chi^2 = \frac{(181 - 220 \cdot e^{-1})^2}{220 \cdot e^{-1}} + \dots$$

Por tanto concluimos que es muy probable que no siga una  $P(1)$

**Ejercicio 10:** Se lanza una moneda hasta que aparece la primera cara. Este experimento se repite 100 veces. Las frecuencias observadas del número de ensayos necesarios hasta que aparece la primera cara son:

Nº ensayos	1	2	3	4	5+
Frecuencia	40	32	15	7	6

¿Se puede concluir que la moneda es perfecta?

Distribución geométrica:

$$P_p(X = k) = (1 - p)^{k-1}p \quad \text{o} \quad P_p(X = k) = (1 - p)^k p$$

Probabilidad bajo  $H_0$ .

$$p_1^0 = \frac{1}{2} \quad p_2^0 = \frac{1}{2^2} \quad \dots \quad p_5 = 1 - \sum_{k=1}^4 p_k$$

Como  $H_0$  es “Los datos provienen de una distribución geométrica  $(\frac{1}{2})$ ”.

Según el test, no rechazamos  $H_0$ .

Si en realidad los datos vienen de una distribución geométrica  $(\frac{1}{3})$ , ¿cuál es la probabilidad de que el test lo detecte? ¿Y si vienen de una distribución geométrica  $(0,52)$ ?

## 1.2. Distribución del test bajo $H_1$

Podemos aumentar la potencia sacrificando  $\alpha$  o aumentando el tamaño de la muestra. Si queremos asegurar una potencia de, por ejemplo, 0,8 o 0,9, necesitamos calcular cuánto debe valer  $n$ .

Para esto, necesitamos conocer la distribución del test bajo  $H_1$ .

Resultado:

$$\lim_{n \rightarrow \infty} P_{\theta_1}(\chi_{k-1}^2 \leq t) = P(\chi_{k-1}^2(\delta) \leq t)$$

Donde  $\delta$  es el parámetro de descentralidad para la  $\chi_{k-1}^2$  descentrada.

**Definición:** La distribución asintótica bajo  $H_1$  del estadístico  $\chi^2$  de prueba de ajuste es una  $\chi^2$  descentrada con  $k - 1$  grados de libertad y parámetro de descentralidad  $\delta$ .

La demostración no está incluida en este curso. Sin embargo, hacemos algunos comentarios sobre esta definición:

### Comentarios:

- Si  $X$  es una variable aleatoria tal que  $X \sim N(0, 1)$ , entonces  $X^2 \sim \chi_1^2$ .
  - Si  $X_1, \dots, X_n$  son v.a.i.i.d.  $N(0, 1)$ , entonces  $\sum_{i=1}^n X_i^2 \sim \chi_n^2$ .
  - Si  $X_1, \dots, X_n$  son v.a.i.i.d.  $N(\mu, \sigma^2)$ , entonces  $\sum_{i=1}^n \left(\frac{X_i}{\sigma}\right)^2 \sim \chi_n^2$  descentrada con parámetro  $\delta$ .

- Para contrastar

$$H_0 : p_0 = (p_1^0, \dots, p_k^0) \\ H_1 : p \neq p^0$$



si bajo  $H_1$  la alternativa es  $p = (p_1^1, \dots, p_k^1)$ , el test  $\chi^2$  sigue una distribución  $\chi_{k-1}^2(\delta)$ , donde  $\delta$  mide la distancia entre los dos vectores:

$$\Delta = \sum_{j=1}^k \frac{(p_j^1 - p_j^0)^2}{p_j^0}; \quad \delta = n \cdot \Delta$$

O equivalentemente:

$$\delta = \sum_{j=1}^k \frac{(n \cdot p_j^1 - n \cdot p_j^0)^2}{n \cdot p_j^0}.$$

3. Existen tablas para  $\chi_{k-1}^{2'}(\delta)$  (por ejemplo, las tablas estándar de  $\chi^2$  descentrada).

### Ejercicio 11:

Durante 60 meses consecutivos se observó la variable aleatoria  $X = \text{N}^\circ$  de accidentes al mes en un cruce de carreteras. Los resultados fueron:

$X$	0	1	2	3+
Nº de meses	23	18	12	7

a) Contrastar la hipótesis de que la distribución de  $X$  es geométrica:

$$G(\theta); p_\theta(X = x) = \theta \cdot (1 - \theta)^x, \quad X = 0, 1, 2, \dots$$

$$H_0 : X \sim G(\theta) = \text{EMV para } X \in \{0, 1, 2, 3+\}$$

$$P_0^0 = \theta, \quad P_1^0 = \theta \cdot (1 - \theta), \quad P_2^0 = \theta \cdot (1 - \theta)^2, \quad P_3^0 = (1 - \theta)^3$$

$$L(\theta, f) = \prod_{j=1}^4 [p_j^0]^{f_j} = \theta^{23} \cdot (\theta \cdot (1 - \theta))^{18} \cdot (\theta \cdot (1 - \theta)^2)^{12} \cdot ((1 - \theta)^3)^7$$

$$\log L(\theta, f) = 53 \log \theta + 63 \log(1 - \theta)$$

$$\frac{d \log(\theta, f)}{d\theta} = \frac{53}{\theta} - \frac{63}{1 - \theta} \implies \hat{\theta} = \frac{53}{53 + 63}$$

Test  $\chi^2$ :

$$\widehat{\chi^2} = \sum_{j=0}^3 \frac{(f_j - 60 \cdot P_j^0(\hat{\theta}))^2}{60 \cdot p_j^0(\hat{\theta})} \sim \chi_2^2$$

b) Potencia de  $H_0 : G(0,4) \quad B_n(2, 0,6)$ :

$$P_1(\chi^2 > C_{0,05}) = P(\chi_3^2(\delta) > C_{0,05})$$

$$S = n \cdot \Delta, \quad \Delta = \sum_{j=0}^3 \left( \frac{(p_j^0 - p_j^1)^2}{p_j^0} \right)$$

## 2. Test de Kolmogorov-Smirnov

### 2.1. Test de Kolmogorov-Smirnov para hipótesis simples

$X_1, \dots, X_n$  i.i.d. con función de distribución  $F$  continua y se quiere contrastar

$$H_0 : F = F_0 \quad H_1 : F \neq F_0$$

El test de Kolmogorov-Smirnov es más potente que el  $\chi^2$  en el caso de  $F$  continua. Tenemos:

- $F_0 \rightarrow$  Función de distribución bajo  $H_0$ .
- $\widehat{F}_n \rightarrow$  Función de distribución muestral o empírica.

$$\widehat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}_{(x_i \leq x)}, \quad x \in \mathbb{R}$$

También se puede definir a partir de los estadísticos de orden:

$$\widehat{F}_n(x) = \begin{cases} 0, & \text{si } x \leq X_{(1)} \\ \frac{i}{n} & \text{si } X_{(i)} \leq x \leq X_{(i+1)}, \quad i = 1, \dots, n-1 \\ 1 & \text{si } X_n \leq x \end{cases}$$

Propiedades:

1.  $n \cdot \widehat{F}_n(x)$  es el total de valores de la muestra menores o iguales a  $x$  y sigue una distribución  $B(n, F(x))$ ,  $\forall x \in \mathbb{R}$
2. Según el resultado anterior, junto con las propiedades de la distribución binomial, se tiene  $\widehat{F}_n(x)$  es un estimador consistente de  $F(x)$

$$\lim_{n \rightarrow \infty} P(|\widehat{F}_n(x) - F(x)| < \varepsilon) \rightarrow 1$$

$$\text{y es CAN: } \sqrt{n} \cdot (\widehat{F}_n(x) - F(x)) \xrightarrow{d} N(0, F(x)(1 - F(x)))$$

3. Por el teorema de Glivenko-Cantelli,  $\widehat{F}_n(x)$  converge uniformemente y casi seguro a  $F(x)$ .

A medida que  $n$  crece, la función escalonada de  $\widehat{F}_n(x)$  con saltos en los valores de los estadísticos de orden  $X_{(1)}, \dots, X_{(n)}$  aproxima la distribución  $F(x)$ .

Por lo tanto cuando  $n$  es grande, la mayor diferencia entre  $\widehat{F}_n(x)$  y  $F(x)$  converge a 0.

Este resultado nos sugiere el estadístico  $D_n = \sup_x |\widehat{F}_n(x) - F(x)|$  el cual es una medida razonable de la precisión de la estimación.

Llamaremos estadístico de Kolmogorov-Smirnov de una muestra a

$$D_n = \sup_x |\widehat{F}_n(x) - F_0(x)|$$

El test rechaza la hipótesis para valores grandes del estadístico ( $D_n > C$ ). Como siempre debemos conocer la distribución de  $D_n$  para obtener el valor crítico.

1. Es importante ver que la máxima diferencia en  $|\widehat{F}_n(x) - F_0(x)|$  es la máxima diferencia en los puntos en los que  $\widehat{F}_n(x) > F_0(x)$  y la máxima en los punto donde  $F_0(x) > \widehat{F}_n(x)$ . Así podemos definir los estadísticos Kolmogorov-Smirnov de un lado.

$$\left. \begin{aligned} D_n^+ &= \sup_x (\widehat{F}_n(x) - F_0(x)) \\ D_n^- &= \sup_x (F_0(x) - \widehat{F}_n(x)) \end{aligned} \right\} D_n = \max\{D_n^+, D_n^-\}$$

$D_n^+$  y  $D_n^-$  son útiles para conocer la distribución.

2. La distribución de  $D_n^+$ ,  $D_n^-$  y  $D_n$  no depende de  $F_0$ , es decir,  $c_\alpha$  será el mismo sin importar si estamos contrastando diferentes hipótesis simples (Como por ejemplo  $N(3, 1)$ ,  $\exp(2)$ ,  $\dots$ ). Se dice que el estadístico es de distribución libre ya que no depende de  $F_0$ .




Figura 2: Visualización del estadístico D+ y D-

Definimos los estadísticos de orden como  $X_{(0)} = -\infty$  y  $X_{(n)} = +\infty$ , por lo tanto podemos definir  $\widehat{F}_n(x) = \frac{i}{n} \quad \forall X_{(i)} \leq x < X_{(i+1)}$ .

$D_n^+$  lo podemos ir calculando a trozos como:

$$D_n^+ = \sup_x (\widehat{F}_n(x) - F_0(x))$$

Tomará un valor máximo únicamente en los extremos del intervalo  $[X_{(i)}, X_{(i+1)})$

$$D_n^+ = \max_{1 \leq i \leq n} \left( \frac{i}{n} - F_0(x_{(i)}) \right)$$

Análogamente:

$$D_n^- = \max_{1 \leq i \leq n} \left( F_0(x_{(i)}) - \frac{i-1}{n} \right)$$

$D_n^+, D_n^-$  (por lo tanto  $D_n$ ) dependen de las variables aleatorias.

$$F_0(X_{(1)}), \dots, F_0(X_{(n)}) \sim U(0, 1)$$

Esto ocurre por la transformación integral de probabilidad, siempre y cuando las variables aleatorias sean continuas.

## 2.2. Test de Kolmogorov-Smirnov para una hipótesis compuesta

Lo anterior nos sirve para hipótesis simp.es. Sin embargo en la mayoría de los escenarios reales, tenemos hipótesis compuestas. Por ejemplo, utilizar Kolmogorov-Smirnov en ANOVA.

Situación:

$$H_0 : F = F_0(\theta) \quad H_1 : F \neq F_0(\theta)$$

Lo haremos como siempre:

1. Estimamos  $\theta$  a partir de los datos (con el Estimador Máximo Verosimil).
2. Se calcula el estadístico Kolmogorov-Smirnov como en el caso de la hipótesis simple:

$$\widehat{D}_n = \sup_x |\widehat{F}_n(x) - F(x)|$$

Se rechaza  $H_0$  con valores grandes de  $\widehat{D}_n$  ( $\widehat{D}_n > C$ ).

Es importante recalcar que  $\widehat{D}_n$  no sigue la misma distribución que  $D_n$ . La distribución no es libre, depende de la familia que estemos evaluando.

Tenemos tablas obtenidas por Lilliefors por simulación para la normal y para la exponencial. Pasos a seguir:

1. Se estiman los parámetros  $\hat{\mu}$  y  $\hat{\lambda}$
2. Se obtiene la muestra estandarizada  $z_1, \dots, z_n$ .
3. Hacer el test ( $H_0 : F_0 \equiv N(0, 1)$  en el caso normal y  $H_0 : F_0 \equiv \exp(1)$  en el caso exponencial).
4. Se rechaza  $H_0$  si  $\widehat{D}_n > C$  para nivel  $\alpha$ . Se usan las tablas de Lilliefors para definir  $C_\alpha$ .

### Caso exponencial:

$$H_0 : F \equiv \exp(\lambda)$$

$$H_1 : F \neq \exp(\lambda)$$

$$\hat{\lambda} = \frac{1}{\bar{X}}, \quad z_i = \frac{X_i}{\bar{X}} \rightarrow z_i \sim \exp(1) \rightarrow \gamma(1, \lambda)$$

El contraste es equivalente a:

$$H_0 : X \sim \gamma\left(1, \frac{1}{\bar{X}}\right) \longleftrightarrow H_0 : Z \sim \gamma(1, 1)$$

Podrás descubrir más estadísticos en el campus virtual

### 3. Test de Shapiro-Wilk

(Este test es más potente que el de Kolmogorov-Smirnov)

Mide como de bien se ajustan los datos a una distribución normal esperada. Se basa en combinación lineal de estadísticos ordenados.

$$W = \frac{(\sum_{i=1}^n a_i \cdot X_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{X})^2}$$

donde

- $X_{(i)}$  es el estadístico de orden  $i$ -ésimo.
- $a_i$  son los coeficientes calculados a partir de los cuantiles esperados de una distribución normal estandar.

$$(a_1, a_2, \dots, a_n) = \frac{m^T \cdot v^{-1}}{\sqrt{m^T \cdot V^{-1} \cdot V^{-1} \cdot m}}$$

tal que

- $m = (m_{(1)}, \dots, m_{(n)})$
- $V$  es la matriz de las covarianzas de  $m_{(i)}$

El numerador nos indica como de bien se alinean los datos con la normalidad esperada. Si los datos son normales, el numerador será grande.




Figura 3: Visualización del QQ plot entre una distribución normal y la muestra

## 4. Primer examen parcial

### Ejercicio 1:

Un artículo, producto de un tipo de componente mecánico que puede deteriorarse a dos velocidades distintas, depende de factores de fabricación no controlados. Se observa que el tiempo de vida ( $X$ ) de cada componente sigue una mezcla de distribuciones exponenciales con las siguientes características:

- Con probabilidad  $p$ , el componente tiene un tiempo de vida  $X$  que sigue una distribución exponencial con parámetro  $\lambda_1$ , lo cual corresponde a componentes con alta resistencia.
- Con probabilidad  $1 - p$ , el componente tiene un tiempo de vida  $X$  que sigue una distribución exponencial con parámetro  $\lambda_2$ , lo cual corresponde a componentes con menor resistencia.

El fichero `Tiempos.RData` corresponde a un conjunto de observaciones independientes  $x_1, x_2, \dots$ , que representan los tiempos de vida medidos en horas de varios componentes.

1. Obtener el EMV y concretar su distribución asintótica para los parámetros del modelo que subyace a partir de estos datos. **Nota:** Planteadas las ecuaciones de verosimilitud, utilice la función `optim` para el cálculo del EMV.

$$f(x, p, \lambda_1, \lambda_2) = p \cdot e^{-\lambda_1 x} + (1 - p) \cdot e^{-\lambda_2 x}$$

$$L(x, p, \lambda_1, \lambda_2) = \prod_{i=1}^n f(x_i, p, \lambda_1, \lambda_2) = \prod_{i=1}^n (p \cdot e^{-\lambda_1 x_i} + (1 - p) \cdot e^{-\lambda_2 x_i})$$

$$\log L(x, p, \lambda_1, \lambda_2) = \sum_{i=1}^n \log f(x_i, p, \lambda_1, \lambda_2)$$

$$\begin{pmatrix} \hat{p} \\ \hat{\lambda}_1 \\ \hat{\lambda}_2 \end{pmatrix} \sim N_3 \left( \begin{pmatrix} p \\ \lambda_1 \\ \lambda_2 \end{pmatrix}, \text{Var}(\text{EMV})_{3 \times 3} \right)$$

2. Obtener el IC de Wald con confianza aproximada de 95 % para cada parámetro del modelo.

$$\hat{p} \pm \text{qnorm}(0,975) \cdot \sqrt{\text{Var}(\hat{p})}$$

3. Obtener el  $p$ -valor basado en el estadístico de Wald para contrastar la hipótesis  $H_0 : \lambda_1 = 0,5$  vs.  $H_a : \lambda_1 \neq 0,5$ .

$$W = \frac{(\hat{\lambda}_1 - 0,5)^2}{\text{Var}(\hat{\lambda}_1)} \sim \chi_1^2$$

4. Obtener el *p-valor* basado en el estadístico de RV para contrastar la hipótesis  $H_0 : \lambda_1 = 0,5$  vs.  $H_a : \lambda_1 \neq 0,5$ .

$$Q_L = 2 \cdot \left[ \log L(\hat{p}, \hat{\lambda}_1, \hat{\lambda}_2, x) - \sup_{p, \lambda_2} \log L(p, \lambda_1 = 0,5, \lambda_2, x) \right] \sim \chi_1^2$$

## Referencias

- [1] Juan Camilo Yepes Borrero,  
*Apuntes Manuscritos Tema 4.*  
Universidad de Valladolid 2024.
- [2] Yolanda Larriba González,  
*Apuntes INFE2 Tema 4.*  
Universidad de Valladolid 2023.